






Stratégie IA & Efficience : Le Cas SavoirPlus

Correction Masterclass de l'Évaluation Bloc 2 — De l'impasse technique au déploiement agile.

Transformer les transcriptions des échanges entre experts-formateurs en fiches pédagogiques claires.



Fine-tuner un modèle Mistral 7B sur des centaines de transcriptions annotées manuellement.



Cet investissement lourd en temps et en ressources est-il vraiment nécessaire dès le départ ?

L'État de l'Art : Comprendre avant de décider

[6] Hugging Face Documentation

La référence officielle pour les étapes concrètes et bonnes pratiques d'entraînement.

[7] Hu et al. (ICLR 2022) - LoRA

L'alternative académique pour l'adaptation à faible rang.

[8] Owen (2024) - The Cost of Fine-tuning

L'analyse empirique indispensable des coûts cachés.


[9] Mistral AI Documentation

Les prérequis techniques exacts pour le modèle cible.

[10] Lewis et al. (NeurIPS 2020) - RAG

La fondation théorique de la Génération Augmentée par la Recherche.


Le Piège des Données : L'illusion de la simplicité



**15 à 30 min par résumé × 500 réunions
= 125 à 250 heures de travail expert**


Un investissement humain massif avant même le premier test technique.

Diagnostic Critique : Pourquoi ré-entraîner est un risque




Le Pivot Stratégique : Séparer le raisonnement de la connaissance

L'Approche Fine-Tuning



Le modèle doit mémoriser à la fois comment résumer ET le contexte spécifique.

L'Approche RAG



Le modèle utilise sa logique native pour traiter un contexte qu'on lui fournit en temps réel.

L'alternative agile : L'Ingénierie de Prompt couplée au RAG permet d'adapter le comportement sans modifier les poids du modèle.

La Matrice de Décision

Critère	Fine-Tuning	Prompt + RAG
Coût financier & humain	Élevé (125+ h)	Quasi nul
Rapidité de déploiement	Semaines / Mois	Quelques jours
Simplicité technique	Expertise ML pointue	Accessible & Itératif
Maintenance	Ré-entraînement	Simple mise à jour de la base
Flexibilité du format	Fixé lors de l'entraînement	Ajustable instantanément

L'approche RAG s'impose comme le standard pour démarrer un projet documentaire.

L'Obstacle du Jargon Interne : Le dernier rempart


Mais nos transcriptions contiennent des acronymes complexes et un jargon propre à SavoirPlus. Le modèle ne les comprendra jamais sans fine-tuning !"

— L'Équipe Technique

C'est un mythe.

La compréhension lexicale ne nécessite pas une modification de l'architecture neuronale. La solution réside dans l'injection contextuelle.

La Parade Algorithmique : Le RAG Lexical



Traçabilité absolue :


On sait d'où vient la définition.



Mise à jour instantanée :

Changer un terme dans le glossaire suffit, coût d'évolution nul.


L'Ascension Progressive : Ne pas brûler les étapes




Cartographie des Risques d'Industrialisation



Le Bouclier : L'Architecture Human-in-the-Loop



La Roadmap de Déploiement en 3 Phases



Mesurer le Succès : Le Tableau de Bord SavoirPlus



Ces métriques conditionnent le passage de la Phase 2 à la Phase 3.

Le rôle du manager IA n'est pas d'adopter la technologie la plus complexe, mais de choisir l'outil cognitif le plus agile, au bon moment, et au meilleur coût.

- ✓ Privilégier l'injection contextuelle (RAG) sur la reprogrammation (Fine-tuning).
- ✓ Protéger le processus par une validation experte humaine.
- ✓ Ne financer le ré-entraînement que lorsque les limites structurelles sont prouvées.